nanoGPT-project

田佳音

June 2024

1 Introduction

自从 2017 年 Attention is all you need 论文的发表,Transformer 架构成为继 MLP、CNN 和 RNN 之后的第四个影响深远的神经网络模型。而由人工智能研究公司 OpenAI 开发的一种基于 Transformer 架构的的自然语言处理模型,GPT 的发布一鸣惊人,不仅在学术界还在每个人的生活中都有十分深刻的影响。在过去的几十年间,神经网络的研究重点放在具有固定目标的单一任务,比如说图片分类、探测垃圾邮件或兴趣推荐等。但是 GPT适用于更广泛、更多元得任务,如文本分类、语言翻译、文本摘要、问答系统、文本生成等多种自然语言处理任务。

但是由技术发展历程知道,如果想要模型的表现优秀需要十分庞大的数据、参数。在一般算力的 CPU 上难以执行,而 Andrej Karpathy 构建了一个可以在 CPU 上运行试验的微型 GPT,即 nanoGPT。为了具体理解每个模块在 Transformer 架构中充当怎样的角色,起到怎样的作用,依据上述nanoGPT 模型由代码自主实现了 GPT 的基本功能。可以根据提供的莎士比亚作品的数据集,生成莎士比亚口吻创作的戏剧或诗篇。通过实际操作,了解到神经网络是如何实际上用代码实现的,以及多头注意机制、迭代次数、前馈层、ResNet、Dropout 函数等在其中的作用。

图 1 是 nanoGPT 的框架。由于只是用于文本生成而非原论文中的机器翻译,所以不需要先将一种语言编码在转换的步骤相较于原论文中的Transformer 架构去掉了编码器部分和交叉注意力机制的部分。

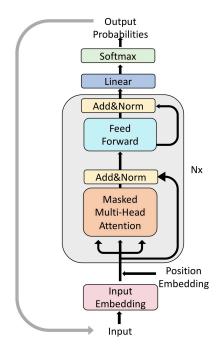


图 1: nanoGPT - model architecture

2 Experiment

2.1 BigramLanguage Model

在模型中使用二元语言模型并且迭代只有 100 次时, 训练后的模型 loss 的值在 4.65 左右。[图 2]

添加了迭代次数至 1000 次后,训练模型,loss 降为 3.70 左右。添加迭代次数到 10 000 次,训练模型得到 loss 为 2.40 左右 [图 4]

2.2 Self Attention Head

2.2.1 Single Head Attention

降低学习率至 1e-3,改变迭代次数至 5000,增加单个自注意力头,模型训练得 loss 依然在 2.40 左右。[图 5]

```
        O traingy
        Empotent

        ● traingy
        Empotent

        ● traingy
        Empotent

        ● traingy
        The product

        ■ traingy
        The production of the producti
```

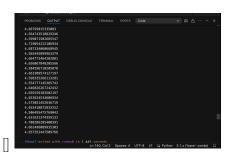


图 2: BigramLanguage Model (100 iterations)

图 3: BigramLanguage Model (1000 iterations)

2.2.2 Multi-Head Attention

并行地建立多个头,改为多头注意力机制,模型训练得 loss 降为 2.28,变化其实并不大。[图 6]

2.3 Position-wise Feed-Forward Network

添加位置前馈层, 训练模型得 loss 降为 2.24。

2.4 Residual Network

添加残差层,训练模型得 loss 降为 2.10 左右。稍微出现了过度拟合的现象。[图 8]

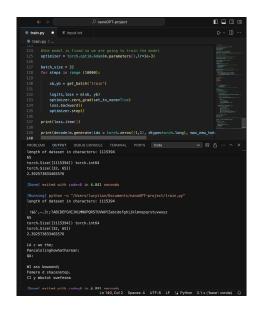


图 4: BigramLanguage Model (10 000 iterations)

2.5 Layer Norm

结合规范层,训练模型, loss 降为 2.09。[图 9]

2.6 Dropout

添加 dropout 层,阻止某些节点进行通信。dropout=0.2,即超过五分之一的中间计算都去除。迭代次数改为 2000 次。训练模型后得到 loss 降至 1.85 左右。[图 10]

迭代次数改为 5000 次。训练后模型 loss 降至 1.68 左右。具有过度拟合的现象。[图 11]

3 Results

基本上完成了根据输入语料生成文本的任务,但是仔细看生成的语言 单词拼写有错有对,并且没有内容逻辑可言。但是通过层层搭建,直观地理 解了 GPT 的原理,每一层存在的作用,数据间的交流。

图 5: Single Head Attention

4 补充

代码的源文件 train.py 在压缩包中, 也包含了数据集 input.txt。压缩包出问题可以在 GitHub 上找到。笔记本下载了 Pytorch 可以在本地 python环境下跑, 训练时间的也很短。可以改变 input 的内容, 不过数据集需要尽量大一点。

下载并解压文件后, cd 到当前文件目录下,即 nanoGPT-project 下。然后只接输入 python train.py 便可以看到 input 数据集中的所有字符数,字符类型,类型数,5000次迭代下 loss 的变化,以及最终生成 500 字的文本。可以更改 input 内容再次训练模型,看生成文本。

 ${\it Git Hub\ address: https://github.com/baazinga/nanoGPT-project}$

```
torch.Size([11394]) torch.int64

Step & trial loss 4.227, val loss 4.2225

Step & trial loss 4.227, val loss 4.2225

Step Medit rain loss 2.427, val loss 2.587

Itep Dabe trial loss 2.427, val loss 2.587

Itep Dabe trial loss 2.427, val loss 2.437

Step Dabe trial loss 2.627, val loss 2.437

Step Dabe trial loss 2.627, val loss 2.438

Step Medit rain loss 2.627, val loss 2.338

Step Medit rain loss 2.627, val loss 2.338

Step Medit rain loss 2.627, val loss 2.338

Step Medit rain loss 2.627, val loss 2.389

Step Medit rain loss 2.727, val loss 2.289

Nome

Soo hits caris Is.

Soo light the ton darge.

Whis bregne cout Lind spoon meand for.

OMCOME fore, at mountem for Lo,
Son yourter, Takes Stature?

Mount with the hamy sillaprecepuith to mou thou s, st sp steramede you on hish be letlieve?

Sociated by are het, ton exibat.

Most good that the magner.

Most good by are het, ton exibat.

Most good by the control in the sociate in the
```

图 6: Multi-Head Attention

```
Section price of Content of Content Co
```

图 7: Feed-Forward Network

```
Manufaction of the control of the co
```

图 8: Residual Network

```
Lipstrictor idases succi, Language-seasedoc-air handouri-project * python train.py length of dataset in characters: 1115304

1854 --, 317 AMBCDFFOHIDLANDMOPSSTUWMOYZabedefghijklamoperstuwwsyz
dorno.Size(11153040) brorn.int64
step 8: train loss 4.1380, vol loss 4.3807
step 8: train loss 4.2380, vol loss 4.3807
step 8: train loss 4.2380, vol loss 4.3808
step 3808: train loss 4.2380, vol loss 2.1860
step 3808: train loss 2.1257, vol loss 2.1860
step 3808: train loss 2.1257, vol loss 2.1860
step 3808: train loss 2.24827, vol loss 2.1860
step 3808: train loss 2.24827, vol loss 2.1892
step 3808: train loss 2.24827, vol loss 2.1892
step 3808: train loss 2.24827, vol loss 2.1894
step 3808: train loss 2.84827, vol loss 2.1894
step 3809: train loss 2.1898, vol loss 2.1898
step 3809: train loss 2.18
```

图 9: Layer Norm

图 10: Dropout (2000 iterations)

```
The state of the s
```

图 11: Dropout (5000 iterations)